

МОДЕЛЬ НЕЙРО-НЕЧЕТКОЙ СЕТИ НА БАЗЕ TENSORFLOW

Долженко А.И.

доктор экономических наук, доцент, РГЭУ (РИНХ)

alexdoljenko@mail.ru

Полиев А.Д.

магистрант, РГЭУ (РИНХ)

poliev.alex@gmail.com

Аннотация: Приведено описание модели нейро-нечеткой сети, реализованной на языке Python базе фреймворка TensorFlow. Приводится состав слоев модели, их назначение и функциональность. Для каждого слоя определяются функции активации, которые отражают этапы нечеткого вывода алгоритма Мамдани. Обучению в модели подвергаются параметры функций принадлежности слоев фазификации и активации заключений нечетких правил, а также коэффициенты доверия правил.

Ключевые слова: нейронная сеть, нечеткие множества, модель, TensorFlow.

MODEL OF NEURO –FUZZY NETWORK BASED ON TENSORFLOW

Doljenko A.I.

Poliev A.D.

Abstract: The description of a neuro-fuzzy network model implemented in the Python language based on the TensorFlow framework is described. The composition of the layers of the model, their purpose and functionality is given. For each layer, activation functions are determined that reflect the stages of the fuzzy derivation of the Mamdani algorithm. Learning in the model are the parameters of the membership functions of the layers of fuzzyfication and activation of the conclusions of fuzzy rules, as well as the confidence factors of the rules

Keywords: neural network, fuzzy sets, model, TensorFlow.

Традиционные математические методы предназначены для обработки точных данных, получить которые можно только с помощью высокоточных измерительных устройств [1]. Сам же человек не может получить точные данные, поэтому оперирует нечеткими понятиями, например высокая температура, низкая скорость и т.д.

Появление компьютеров, рост их вычислительной мощности предопределило создание моделей искусственного интеллекта, сходного с

интеллектом человека. Создание области математики, которая в последствии была названа теорией нечетких множеств [2], открыло новые возможности для исследований в этой сфере.

Эффективность применения методов нечеткого моделирования и управления можно существенно повысить, если их использовать совместно и во взаимодействии с методами, основанными на искусственных нейронных сетях и генетических алгоритмах [3, 4].

На сегодняшний день существует множество инструментов, библиотек для создания искусственных нейронных сетей, таких как TensorFlow, Scikit-learn, MatLab и др. Сравнивая TensorFlow с названными инструментами, можно выделить их преимущества: наиболее популярный инструмент для разработки; возможность разработки на разных языках программирования; более низкоуровневая библиотека, что позволяет лучше использовать ресурсы CPU и GPU.

Пакет Tensor Flow не обладает возможностями построения нечетких моделей и нейро-нечётких сетей. Разработка нейро-нечёткой модели на этой платформе позволит интегрировать возможность создания и обучения нейронных сетей с нечёткими моделями.

При разработке нейро-нечеткой модели на языке Python и пакете Tensor Flow ставилась задача реализации сети прямого распространения сигнала, использующей алгоритм вывода Мамдани [3] и адаптацию параметров сети методом градиентного спуска путем обратного распространения ошибки. В разрабатываемой нейро-нечеткой сети адаптация должна проводиться для параметров функций принадлежности предпосылок и заключений нечетких правил, а также коэффициентов доверия нечетких правил.

Разрабатываемая модель содержит следующие слои: слой фазификации; слой Т-нормы (нечеткая операция «И»); слой S-нормы (нечеткая операция «ИЛИ»); слой активации; слой аккумуляции; слой дефазификации.

Слой фазификации предназначен для создания лингвистической переменной, её термов и вычисления степени принадлежности входных переменных нечетким множествам, определяемым терминами лингвистических переменных. Функцией активации для этого слоя является функция принадлежности нечеткого множества.

Слой Т-нормы реализует агрегирование степени истинности предпосылок правил базы знаний. Функцией активации слоя — конъюнкция степеней истинности предпосылок правил (Т-норма), алгебраическое, граничное и драстическое произведение истинности предпосылок правил [3]. При использовании Т-нормы степень принадлежности входной переменной нечеткому множеству определяется по следующей формуле:

$$\alpha_1 = \min\{\mu_{A_{11}}(x'_1), \mu_{A_{21}}(x'_2)\}$$

Слой S-нормы реализует объединение правил нечетких множеств. Функция активации – дизъюнкция степеней истинности предпосылок правил (S-норма или Т-конорма) [3] в соответствии с формулой:

$$\beta_i = \max\{\alpha_{i1}, \dots, \alpha_{ij}\}$$

Слой активации реализует активацию заключений нечетких продукционных правил. В качестве функции активации слоя используют min-активизацию, prod-активизацию и average-активизацию. При использовании S-нормы степень принадлежности входной переменной нечеткому множеству определяется по следующей формуле:

$$\mu_{B'_i}(y) = \min\{\beta_i, \mu_{B_i}(y)\}.$$

Слой аккумуляции реализует аккумулятивное активированных заключений правил. Функцией активации этого слоя могут быть следующие методы нечеткой логики: max-дизъюнкции, алгебраической, граничной, драстической или λ суммы. При использовании max-дизъюнкции аккумулятивное заключение правил производится по следующей формуле:

$$\mu_{B'(y)} = \max\{\mu_{B'_1}(y), \mu_{B'_2}(y)\}.$$

Слой дефазификации формирует чёткое значение y выхода модели. Чёткое значение y' выхода модели рассчитывается как центр тяжести функции принадлежности $\mu_B(y)$ по следующей формуле:

$$y' = \frac{\sum_{r=1}^{Y_{max}} y_r \cdot \mu_{B'}(y_r)}{\sum_{r=1}^{Y_{max}} \mu_{B'}(y_r)},$$

где Y_{max} – число элементов y_r в дискретизированной для вычисления «центра тяжести» области Y .

На листинге 1 представлена нейро-нечеткая модель.

Листинг 1.

```
model = tf.keras.models.Sequential([
    # Слой фазификации
    LingvisticVariable(list_mf=mf, list_params=pars),
    # Слой преобразования формы данных для слоя t-нормы
    Reshape_Layer(9, 2, graph, 1),
    # Слой t-норм
    TSnorm_Layer(tf_minT),
    # Слой преобразования формы данных для слоя s-нормы
    Reshape_Layer(3, 4, graph1, 0),
    # Слой s-норм
    TSnorm_Layer(tf_maxS),
    # Слой активации
    Ling_Weight_Layer(mf, pars, universe, w),
    # Слой аккумуляирования
    Accumulate_Layer()
    # Слой дефазификации
    Defuzzyfication_Layer(universe)])
```

Модель включает слой фазификации (LingvisticVariable), слои преобразования формы данных для слоя t/s-норм (Reshape_Layer), слои t/s-норм (TSnorm_Layer), слой активации (Ling_Weight_Layer), слой аккумуляирования (Accumulate_Layer) и слой дефазификации (Defuzzyfication_Layer).

При компиляции модели задается оптимизатор обучения модели (adam), функция ошибки (sparse_categorical_crossentropy) и метрики (accuracy) (листинг 2).

Листинг 2.

```
model.compile(optimizer='adam',  
loss='sparse_categorical_crossentropy',  
metrics=['accuracy'])
```

Обучение модели реализуется методом `fit`, а оценка – `evaluate` на обучаемых (`x_train`, `y_train`) и тестовых (`x_test`, `y_test`) данных (листинг 3).

Листинг 3.

```
model.fit(x_train, y_train, epochs=7)  
  
model.evaluate(x_test, y_test, verbose=2)
```

Обучение проводится на 7 эпохах. Результаты тестового моделирования нейро-нечеткой сети показали приемлемые показатели ошибки (`loss`: 0.0238) и точности (`accuracy`: 0.9632) при моделировании сети в двумя входами и одним выходом.

БИБЛИОГРАФИЧЕСКИЙ СПИСОК

1. Пегат А. Нечеткое моделирование и управление. – 2-е изд. – М.: БИНОМ. Лаборатория знаний, 2013. – 798 с.
2. Заде Л.А. Понятие лингвистической переменной и его применение к принятию приближенных решений. – М: «Мир», 1976.
3. Борисов В.В., Круглов В.В., Федулов А.С. Нечеткие модели и сети. – М.: Горячая линия – Телеком. 2007. – 284 с.
4. Сахарова Л.В. Использование теории нечётких множеств для оптимизации механизмов профессиональной подготовки // Интеллектуальные ресурсы – региональному развитию. – 2016. – С. 114-118.